(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121567163 A
(43)申请公布日 2026.02.24

(21)申请号 202511801188.4

(22)申请日 2025.12.02

(71)申请人 西安电子科技大学
地址 710071 陕西省西安市雁塔区太白南路2号

(72)发明人 承楠 张岳 贾宏刚 龚臣 孙瑞锦

(74)专利代理机构 西安嘉思特知识产权代理事务所(普通合伙) 61230
专利代理师 梁柱

(51)Int.Cl.
H04B 7/0413(2017.01)
H04B 7/0456(2017.01)
H04L 25/02(2006.01)
G06N 3/045(2023.01)

权利要求书2页 说明书11页 附图4页

(54)发明名称

基于双路Transformer和动态课程学习的鲁棒SVD近似方法

(57)摘要

本申请提供了一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法,包括获取MIMO系统的信道矩阵,并输入至训练完成的SVD近似网络中,使其将所述信道矩阵分解为列视角序列和行视角序列,并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理,从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵。本申请通过双路并行编码器架构和内部的线性注意力机制,并结合高效的MLP解码器,可以大幅度提高分解效率和准确性,满足了无线通信低时延、实时处理、高准确性的要求。此外,本申请的自适应F范数奇异值缩放策略,有效克服了训练不稳定问题,使得模型对不同信道质量均具有良好的预测稳定性。

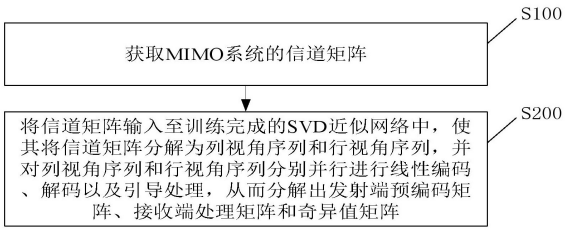

CN 121567163 A

1.一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,包括:

S100,获取MIMO系统的信道矩阵;

S200,将所述信道矩阵输入至训练完成的SVD近似网络中,使其将所述信道矩阵分解为列视角序列和行视角序列,并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理,从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵。

2.根据权利要求1所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理包括:

对所述列视角序列和行视角序列分别进行线性编码,得到列之间相关的列特征矩阵和行之间相关的行特征矩阵;

将所述列特征矩阵与所述行特征矩阵进行拼接得到拼接特征矩阵;

对所述列特征矩阵、所述行特征矩阵和所述拼接特征矩阵进行并行解码得到发射端初始预编码矩阵、接收端初始处理矩阵和初始奇异值矩阵;

对所述发射端初始预编码矩阵和接收端初始处理矩阵进行两次迭代得到发射端预编码矩阵、接收端处理矩阵;

对所述初始奇异值矩阵进行映射得到奇异值矩阵。

3.根据权利要求2所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述SVD近似网络包括:鲁棒归一化模块、双路并行编码器模块、拼接模块、三路并行解码器模块和后处理模块;

所述鲁棒归一化模块用于将所述信道矩阵分解为列视角序列和行视角序列;

所述双路并行编码器模块用于对所述列视角序列和行视角序列分两路分别进行线性编码,得到列之间相关的列特征矩阵和行之间相关的行特征矩阵;

所述拼接模块用于将所述列特征矩阵与所述行特征矩阵进行拼接得到拼接特征矩阵;

所述三路并行解码器模块用于分三路分别对所述列特征矩阵、所述行特征矩阵和所述拼接特征矩阵进行并行解码得到发射端初始预编码矩阵、接收端初始处理矩阵和初始奇异值矩阵;

所述后处理模块用于对所述发射端初始预编码矩阵和接收端初始处理矩阵进行两次迭代得到发射端预编码矩阵、接收端处理矩阵;对所述初始奇异值矩阵进行映射得到奇异值矩阵。

4.根据权利要求3所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述双路并行编码器模块包括列编码器和行编码器,所述列编码器和行编码器均包括若干层堆叠的Transformer编码层;所述列编码器中的每一个Transformer编码层通过自注意力和前馈网络对列之间的相关性特征进行提取,得到列特征矩阵;所述行编码器中的每一个Transformer编码层通过自注意力和前馈网络对行之间的相关性特征进行提取,得到行特征矩阵。

5.根据权利要求3所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述三路并行解码器模块包括:预编码矩阵解码器、处理矩阵解码器和奇异值解码器;所述预编码矩阵解码器、处理矩阵解码器和奇异值解码器均采用MLP解码器;

所述预编码矩阵解码器用于对所述行特征矩阵进行解码,得到发射端初始预编码矩

阵；

所述处理矩阵解码器用于对所述列特征矩阵进行解码,得到接收端初始处理矩阵；

所述奇异值解码器用于对所述拼接特征矩阵进行解码,得到初始奇异值矩阵。

6.根据权利要求5所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述奇异值解码器通过预测相对比例向量,再将所述信道矩阵的F范数作为尺度因子,对所述相对比例向量进行缩放得到初始奇异值矩阵。

7.根据权利要求3所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述后处理模块包括两个并行的正交引导模块以及映射模块；

所述两个并行的正交引导模块分别对所述发射端初始预编码矩阵和接收端初始处理矩阵,在前向传播过程中施加两次迭代,从而重塑出发射端预编码矩阵和接收端处理矩阵；

所述映射模块用于对所述初始奇异值矩阵进行映射得到奇异值矩阵。

8.根据权利要求7所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,所述正交引导模块还用于在SVD近似网络训练过程中,提供指向正交流形的密集梯度,从而辅助优化训练。

9.根据权利要求1所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,在SVD近似网络的训练过程中采用复合损失函数作为每次迭代训练的损失函数,所述复合损失函数包括重建精度损失和结构准确性损失,并采用随着迭代次数动态增长的权重变量调整所述重建精度损失和结构准确性损失。

10.根据权利要求1所述的基于双路Transformer和动态课程学习的鲁棒SVD近似方法,其特征在于,在S200之后,所述方法还包括：

利用所述发射端预编码矩阵、接收端处理矩阵和奇异值矩阵完成信号传输。

基于双路Transformer和动态课程学习的鲁棒SVD近似方法

技术领域

[0001] 本申请属于通信传输技术领域,具体涉及一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法。

背景技术

[0002] 全球移动数据流量的爆发式增长,驱动无线通信系统持续演进。为了适应高速率需求,无线系统架构正由传统的MIMO系统逐步发展至大规模多输入多输出(Massive MIMO),乃至超大规模MIMO(Extremely Large-Scale MIMO, XL-MIMO)系统。天线规模的数量级扩展,极大地丰富了系统的空间自由度,从而显著提升系统容量和频谱效率。

[0003] 在MIMO系统中,预编码是实现高效信息传输的关键技术。一个典型的MIMO系统信号模型可表示为$y=Hx+n$,其中x为基站的发射信号向量,H为MIMO信道矩阵,y为用户接收信号向量。为了实现高效传输,发射信号x通常由线性预编码生成,即$x=Ps$(s为待发送的信息符号)。

[0004] 奇异值分解(Singular Value Decomposition, SVD)是实现信道解耦和最优线性预编码(如SVD预编码方案)的核心操作。通过SVD,信道矩阵H可被分解为$H=U\Sigma V^H$,其中U和V为酉矩阵。若令预编码矩阵$P=V$,接收处理矩阵$R=U^H$,则系统可等效解耦为一组并行的独立子信道,实现空间多路复用与干扰消除。

[0005] 然而,随着天线数量(即矩阵维度M和N)的急剧增加,SVD的计算复杂度成为系统实现的瓶颈。传统SVD算法(如Jacobi迭代)的计算复杂度高达$O(N^3)$或$O(MN^2)$,这难以满足未来无线系统低功耗、低时延的严格要求。

[0006] 目前用于实现MIMO信道矩阵H的SVD的技术路径主要包括两大类:传统数值分解算法,以及利用深度学习模型进行近似求解的方法。两类方案各具特点,但在实际部署中均存在一定局限。

[0007] (1)传统数值计算方法

传统SVD通常依赖数值线性代数的迭代式算法,例如Jacobi方法、QR分解、Golub-Reinsch算法等。这类方法的主要目标是通过连续的正交变换,逐步将矩阵逼近对角化结构,以获得精确的奇异值与奇异向量,但与此同时也需要面临一系列的问题。

[0008] 首先基于传统方法的SVD分解计算复杂度较高,典型时间复杂度约为:$O(MN^2+N^3)$,其中每一项均具有明确的物理意义:MN^2代表对信道矩阵进行逐步正交化、消去非对角元素的代价,矩阵越“宽”,这一部分越明显;N^3对应核心特征分解过程,是算法中最耗时的一步,特别在高维MIMO通信系统(例如64×64或更大尺寸)中会迅速到达瓶颈。因此,随着MIMO天线数量的增加,对应矩阵中M与N的同时增加,基于传统SVD分解的延迟将呈立方级上升,因此难以满足实时通信系统对毫秒级反馈的要求。

[0009] 其次基于传统方法的SVD分解的实现上对实际的设备存储空间和硬件算力成本普遍偏高,传统算法需要在每步迭代中维护多个中间矩阵(如旋转矩阵、残差矩阵等),其空间

复杂度通常不低于$O(MN+N^2+M^2)$。其中：MN用于保存信道矩阵以及若干过渡矩阵。N^2/M^2用于保存不断更新的正交矩阵(U和V)。通常在基站侧FPGA/ASIC上，这类高维矩阵的存储与移动会带来明显的片上SRAM压力，也会增加访存延迟。

[0010] 最后是基于传统方法的SVD分解迭代收敛耗时，传统算法需要依赖多轮迭代才能达到指定精度(如10^{-6}级别)。在快速移动场景下例如高速铁路、车联网等应用场景，信道快速变化会导致作业周期过长而引起的SVD更新频率跟不上信道变化，同时反馈开销增大导致系统吞吐量降低。

[0011] 表1中给出了常见MIMO信道矩阵的传统SVD算法复杂度与所需资源开销对比。因此虽然精确数值的SVD更可靠，但随着MIMO信道矩阵的增大，需要更多的时间、空间与计算资源，从而难以在硬件平台上实现。因此不适合实时大规模MIMO系统。

[0012] 表1 传统SVD算法在不同MIMO矩阵尺寸下的性能开销统计表

MIMO信道矩阵大小	分解时间（ms）	占用空间内存（MB）	分解时间标准差（ms）	计算乘加次数
32x32	0.10	0.01	0.06	43,690
64x64	0.28	0.03	0.11	349,525
128x128	31.71	0.12	37.51	2,796,202
256x256	172.87	0.50	132.19	22,369,621
512x512	1,428.66	2.00	857.43	178,956,970
1024x1024	5,412.78	8.00	2,128.08	1,431,655,765

[0013] (2)基于深度学习的近似求解方法

与此同时，近年来随着AI技术的快速发展，市面上也出现了尝试用CNN、MLP、标准Transformer等“黑箱式”网络架构来逼近SVD映射关系的方法。这类方法通常将信道矩阵H输入到网络，以回归方式同时预测U、S、V三组SVD矩阵结果。

[0014] 但现有深度学习方案普遍存在以下问题：

首先是通用网络没有针对信道矩阵进行定制版结构性设计，例如CNN主要适合卷积平移不变模式，而信道矩阵通常不存在“局部平移特性”，同时CNN感受野较小导致无法一次性观察到全局信息；Transformer虽能学习全局关系，但常规自注意力是为序列建模而设计，并未结合信道矩阵自身的格状结构、复数特性、能量分布规律。因此模型效率不足，推理代价高；其次是时间复杂度和存储开销不具备通信系统可部署性，以经典的Transformer架构为例，其注意力复杂度为$O(L^2d)$。其中：L=M×N将信道矩阵展开后长度非常大(例如64×64的信道矩阵直接变成4096维序列)，d表示特征维度，与模型宽度相关。在这种情况下，时间复杂度呈二次方爆炸、注意力矩阵需要存储$L\times L$的中间结果，显著增加显存/片上SRAM占用、推理耗时较大，不适合实时CSI处理；最后是模型精度受限且鲁棒性不强，现有深度学习方案通常作为“端到端回归器”，并未引入奇异值分解的数学结构、正交性约束及能量守

恒约束等信息,从而导致模型输出的U、V往往不严格满足正交性、逼近误差随环境、信噪比(SNR)、场景变化而增大以及在高维MIMO信道矩阵上难以进行扩展。

发明内容

[0015] 为了解决现有技术中存在的上述问题,本申请提供了一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法。本申请要解决的技术问题通过以下技术方案实现:

一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法包括:

S100,获取MIMO系统的信道矩阵;

S200,将所述信道矩阵输入至训练完成的SVD近似网络中,使其将所述信道矩阵分解为列视角序列和行视角序列,并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理,从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵。

[0016] 有益效果:

1、本申请通过双路并行编码器架构和内部的线性注意力机制,并结合高效的MLP解码器,使得在GPU上的前向传播速度达到了传统SVD算法的近2倍,用时缩短至53.6%,满足了无线通信低时延、实时处理的要求。

[0017] 2、本申请通过基于数学原理的行列空间解耦设计,使得网络学习目标更明确;结合可微截断正交引导和动态权重训练策略,使得SVD近似误差收敛至0.571的低水平,且正交损失接近于0,保证了SVD分解的数学结构准确性。

[0018] 3、本申请的自适应F范数奇异值缩放策略,将不稳定的绝对值回归问题转化为稳定的相对比例预测,有效克服了奇异值量级差异悬殊带来的训练不稳定问题,使得模型对不同信道质量(不同奇异值分布)均具有良好的预测稳定性。

[0019] 以下将结合附图及实施例对本申请做进一步详细说明。

附图说明

[0020] 图1是本申请提供的一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法的示意图;

图2是本申请提供的SVD近似网络的结构示意图;

图3是本申请提供的不同信道矩阵奇异值的对比及衰减趋势的示意图;

图4是本申请提供的训练过程重建损失收敛曲线的示意图;

图5是本申请提供的训练过程正交损失收敛曲线的示意图;

图6是本申请提供的训练过程总损失收敛曲线的示意图;

图7是本申请提供的训练过程学习率变化曲线的示意图。

具体实施方式

[0021] 下面结合具体实施例对本申请做进一步详细的描述,但本申请的实施方式不限于此。

[0022] 如图1所示,本申请提供了一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法包括:

S100,获取MIMO系统的信道矩阵;

从SVD的数学本质及其在MIMO系统中的物理含义出发,对信道矩阵的行列空间进行显式建模。设信道矩阵记为$H \in C^{(M \times N)}$,在典型的大规模MIMO或XL-MIMO场景中,M、N通常较大,直接对H进行精确SVD将带来较高的计算复杂度和时延。本申请旨在利用神经网络对H的SVD结果进行高精度近似,同时尽可能保持SVD的几何结构和物理含义。

[0023] 从通信系统角度看,矩阵H描述了发射天线到接收天线之间的复数信道增益,对H进行SVD可得到:

$$H = U \Sigma V^{\mathrm{H}};$$

其中U和V的列向量在物理上分别对应接收端和发射端的一组正交空间波束或空间模式,Σ的对角元素(奇异值)则反映各个等效空间子信道的增益大小。U为接收端处理矩阵,V为发射端预编码矩阵。在理想情况下,通信系统可以在这些正交子信道上进行预编码和功率分配,从而逼近信道容量。

[0024] 从线性代数的角度,对应接收端处理矩阵U的列向量张成了H的列空间,对应发射端预编码矩阵V的列向量张成了H的行空间,并且这两组向量都是标准正交基。这意味着,U的求解本质上是“在列空间中找一组标准正交基”,V的求解本质上是“在行空间中找一组标准正交基”。

[0025] 基于上述认识,本申请提出如下核心构思:

左奇异矩阵(接收端处理矩阵)U的信息主要蕴含在H的列与列之间的相关性结构中,是对“列空间”的正交基学习问题。右奇异矩阵(发射端预编码矩阵)V的信息主要蕴含在H的行与行之间的相关性结构中,是对“行空间”的正交基学习问题。

[0026] 然而,现有通用AI方法(例如将H展平成一维向量送入全连接网络,或采用单一路径的Transformer/CNN对整块矩阵进行编码)在特征提取过程中往往混合甚至破坏H的行列代数结构,导致:(1)列空间与行空间的信息在网络内部严重耦合;(2)网络无法针对“列与列”“行与行”的结构进行定向建模;(3)学习任务变得过于复杂,不利于收敛和精度提升。

[0027] S200,将所述信道矩阵输入至训练完成的SVD近似网络中,使其将所述信道矩阵分解为列视角序列和行视角序列,并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理,从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵。

[0028] 在本申请一种具体的实施方式中,所述对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理包括:

对所述列视角序列和行视角序列分别进行线性编码,得到列之间相关的列特征矩阵和行之间相关的行特征矩阵;

具体的,输入矩阵H(维度为$M \times N$)被逻辑上拆解为两种不同视角的序列:

列视角序列:将H视为由N个列向量组成,即表示为:

$$H = [h_1, h_2, \ldots, h_N]$$

[0029] 其中,$c_j \in C^M$为第j个列向量。每个列向量经过适当的复数到实数映射(例如将实部、虚部分别作为不同通道)后,形成一个长度为N的列序列,用于刻画列空间结构。

[0030] 行视角序列:将H视为由M个行向量组成,即表示为:

$$H^{\mathrm{T}}=\left[r_1,r_2,\ldots,r_M\right]$$

[0031] 其中$r_i\in C^N$为第i个行向量。通过同样的映射方式,将每个行向量转换为实值特征向量,形成一个长度为M的行序列,用于刻画行空间结构。

[0032] 将所述列特征矩阵与所述行特征矩阵进行拼接得到拼接特征矩阵;

对所述列特征矩阵、所述行特征矩阵和所述拼接特征矩阵进行并行解码得到发射端初始预编码矩阵、接收端初始处理矩阵和初始奇异值矩阵;

对所述发射端初始预编码矩阵和接收端初始处理矩阵进行两次迭代得到发射端预编码矩阵、接收端处理矩阵;

对所述初始奇异值矩阵进行映射得到奇异值矩阵。

[0033] 为解决通用AI方法分解存在的技术问题,本申请提出了一种基于行列空间解耦的双路Transformer编码器架构,从网络结构层面与SVD的数学结构对齐。参考图2所示,本申请的SVD近似网络包括:鲁棒归一化模块、双路并行编码器模块、拼接模块、三路并行解码器模块和后处理模块;所述鲁棒归一化模块用于将所述信道矩阵分解为列视角序列和行视角序列;所述双路并行编码器模块用于对所述列视角序列和行视角序列分两路分别进行线性编码,得到列之间相关的列特征矩阵和行之间相关的行特征矩阵;所述拼接模块用于将所述列特征矩阵与所述行特征矩阵进行拼接得到拼接特征矩阵;所述三路并行解码器模块用于分三路分别对所述列特征矩阵、所述行特征矩阵和所述拼接特征矩阵进行并行解码得到发射端初始预编码矩阵、接收端初始处理矩阵和初始奇异值矩阵;所述后处理模块用于对所述发射端初始预编码矩阵和接收端初始处理矩阵进行两次迭代得到发射端预编码矩阵、接收端处理矩阵;对所述初始奇异值矩阵进行映射得到奇异值矩阵。

[0034] 继续参考图2,所述双路并行编码器模块包括列编码器和行编码器,所述列编码器和行编码器均包括若干层堆叠的Transformer编码层;所述列编码器中的每一个Transformer编码层通过自注意力和前馈网络对列之间的相关性特征进行提取,得到列特征矩阵;所述行编码器中的每一个Transformer编码层通过自注意力和前馈网络对行之间的相关性特征进行提取,得到行特征矩阵。

[0035] 本申请将H矩阵的列序列作为第一输入序列送入列编码器。列编码器可以包括若干层堆叠的Transformer编码层,每一层通过自注意力和前馈网络对“列与列”之间的相关性进行特征提取。列编码器专门面向列空间建模,将其输出的潜在特征定向送入后续的U矩阵解码器,用于预测左奇异矩阵U的近似表示。将H矩阵的行序列作为第二输入序列送入行编码器。行编码器结构与列编码器类似,同样由若干层Transformer编码层构成,其学习目标是“行与行”之间的相关性。行编码器专门面向行空间建模,将其输出的潜在特征定向送入后续的V矩阵解码器,用于预测右奇异矩阵V。

[0036] 本申请在网络结构上实现了列空间与行空间的物理隔离和数学解耦:列编码器仅负责“列空间正交基”的相关信息提取,行编码器仅负责“行空间正交基”的相关信息提取,避免了中间特征的混淆。

[0037] 与现有将H直接输入单一路径网络的方案相比,本申请将原本一个复杂而纠缠的

SVD求解任务,拆分为两个结构更加清晰的子任务:列空间基学习与行空间基学习。这种拆分一方面更贴近SVD的理论结构,有利于约束网络搜索空间;另一方面也能显著提升训练的稳定性和最终的近似精度。

[0038] 虽然双路编码器在结构上解耦了行列空间,但在大规模MIMO场景下,列序列长度N、行序列长度M均可能较大,若直接采用标准自注意力机制,仍然会遇到计算复杂度随序列长度二次增长的问题。标准自注意力需要对长度为L的序列中任意两个位置之间的相关性进行显式计算,其核心是构造一个$L \times L$的相关性矩阵,因而在序列长度维度上的时间和空间复杂度均为$O(L^2)$。当L分别取M和N并达到较大规模时,编码器的计算与存储开销将迅速增大,难以满足实时或准实时信道处理的要求。

[0039] 从计算过程看,线性注意力具有如下特点:

首先计算与序列整体相关的全局统计量$\phi(K)^{\mathrm{T}} V$,这一步仅依赖于序列长度L,计算复杂度与L近似成线性关系,约为$O(Ld_k d_v)$,其中d_k代表键/查询的特征维度,d_v代表值的特征维度;随后,对于每个位置i,仅需用局部的第i个位置经过特征映射后的查询向量$\phi(Q)_i$与上述全局统计量进行矩阵-向量乘法和标量归一化,整体复杂度同样为$O(Ld_k d_v)$。因此,与标准自注意力需要构造$L \times L$的相关性矩阵不同,线性注意力通过“先聚合键与值,再与查询相乘”的方式,避免了二次方量级的相关性矩阵构造,使得注意力层在序列长度维度上的总复杂度由$O(L^2)$降低为近似线性的$O(L)$。

[0040] 在本申请的双路编码器中:对列编码器而言,序列长度为N,采用线性注意力后,其每层注意力计算复杂度由$O(N^2)$降低为约$O(N)$;对行编码器而言,序列长度为M,采用线性注意力后,其每层注意力计算复杂度由$O(\mathrm{M}^2)$降低为约$O(\mathrm{M})$。

[0041] 综合考虑列、行两路,在大规模天线阵列场景下,本申请能够在保持对列与列、行与行的相关性建模能力的前提下,将编码阶段的计算开销控制在与天线数量近似线性增长的水平,显著降低了整体SVD近似方法的计算复杂度和推理时延。

[0042] 继续参考图2,所述三路并行解码器模块包括:预编码矩阵解码器、处理矩阵解码器和奇异值解码器;预编码矩阵解码器、处理矩阵解码器和奇异值解码器均采用MLP解码器;

所述预编码矩阵解码器用于对所述行特征矩阵进行解码,得到发射端初始预编码矩阵;

所述处理矩阵解码器用于对所述列特征矩阵进行解码,得到接收端初始处理矩阵;

所述奇异值解码器用于对所述拼接特征矩阵进行解码,得到初始奇异值矩阵。其中,所述奇异值解码器通过预测相对比例向量,再将所述信道矩阵的F范数作为尺度因子,对所述相对比例向量进行缩放得到初始奇异值矩阵。

[0043] 本申请针对基于Transformer的MIMO信道矩阵SVD近似中的奇异值向量(s向量)预测不准确和训练不稳定的关键难题,提出了一种自适应Frobenius范数(F-Norm)奇异值缩

放策略。该策略通过将奇异值的绝对值回归问题解耦为稳定的相对比例预测和尺度因子缩放,显著提升了模型的训练稳定性和预测精度。

[0044] 奇异值预测的挑战与可视化依据如下。

[0045] (1)信道矩阵H的奇异值$\mathbf{s}=[\sigma_1,\sigma_2,\ldots,\sigma_r]^T$在无线通信中面临如下挑战,从而导致直接使用神经网络进行绝对值回归极其困难。首先是非线性长尾衰减特性:MIMO信道矩阵的奇异值通常具有长尾分布特性,即只有少数几个主奇异值(如σ_1,σ_2)承载了绝大部分矩阵能量,而其余奇异值呈现快速衰减至趋近于零的趋势($\sigma_1 \gg \sigma_2 \gg \ldots \gg \sigma_r$)。其次是样本间量级差异悬殊:不同信道条件下的矩阵H能量尺度差异巨大,主奇异值的量级差异可能高达数千倍。这种分布不均、尺度差异巨大的目标奇异值向量会使得神经网络训练过程中梯度极其不稳定,以至于难以收敛到泛化能力较强的最优解。

[0046] 如图3所示,图3中清晰地展示了10个真实小区场景下128x128大小的MIMO信道矩阵的前16个奇异值,由图3可知不同信道矩阵的垂直间距量级悬殊,10条折线在奇异值索引1处(即最大奇异值σ_1)的垂直位置差异巨大,直接证明了不同样本间的绝对尺度差异。所有信道矩阵的奇异值向量呈现出均为长尾特性的衰减趋势,所有折线均呈现出相似的快速下降趋势,证实了奇异值的非线性长尾衰减特性。正是这种量级悬殊与长尾衰减并存的特点,使得直接回归S向量成为SVD近似中的一大技术瓶颈。

[0047] 本申请转而分析矩阵的F范数,该范数与奇异值存在严格的数学关系,它稳定地锚定了矩阵的整体能量尺度大小。矩阵H的F范数定义为其所有元素平方和的平方根,且与奇异值的关系如下:

$$\|\mathbf{H}\|_F^2=\sum_{i=1}^{r}\sigma_i^2$$

[0048] 其中,σ_i为矩阵H的第i个奇异值,r为矩阵的秩。

[0049] 本申请进一步揭示了F范数与最大奇异值σ_1之间的近似关系。证明过程如下:

(1)设奇异值按降序排列$\sigma_1 \geq \sigma_2 \geq \ldots \geq \sigma_r$。记$\epsilon=\dfrac{\sum_{i=2}^{r}\sigma_i^2}{\sigma_1^2}$。

[0050] 根据F范数定义,矩阵F范数的平方可以表示为:

$$\|\mathbf{H}\|_F^2=\sum_{i=1}^{r}\sigma_i^2=\sigma_1^2+\sum_{i=2}^{r}\sigma_i^2=\sigma_1^2\left(1+\frac{\sum_{i=2}^{r}\sigma_i^2}{\sigma_1^2}\right)=\sigma_1^2(1+\epsilon)$$

[0051] 其中,ϵ表示其余非主奇异值的平方和与最大奇异值平方的比值。于是,F范数可以表示为:

$$\|\mathbf{H}\|_F=\sigma_1\sqrt{1+\epsilon}$$

[0052] 当矩阵能量高度集中于主奇异值时,有$\epsilon \ll 1$。此时,对$\sqrt{1+\epsilon}$泰勒展开可得到:

$$\sqrt{1+\epsilon}=1+\frac{\epsilon}{2}+O(\epsilon^2)$$

[0053] 因此,F范数与最大奇异值σ_1近似满足:

$$\|\mathbf{H}\|_F \approx \sigma_1\left(1+\frac{\epsilon}{2}\right)$$

[0054] 此证明表明,F范数是一个标量,它稳定地、近似地锚定并反映了最大奇异值σ_1的量级,从而表征了整个奇异值向量的整体能量尺度。

[0055] 基于上述观察,F范数是一个表征奇异值整体尺度的稳定锚点。本申请提出一种两步预测策略,将不稳定的绝对值回归问题,转化为稳定的“相对比例预测+尺度缩放”问题:

Transformer模型的奇异值解码器不直接参与预测绝对奇异值,而是预测一个相对比例向量$\hat{\mathbf{p}}$。解码器输出首先经过Softplus激活函数,以确保预测值非负。将非负输出向量(预测的初始奇异值矩阵)$\hat{\mathbf{s}}$进行L2范数归一化,即除以向量的L2模长得到奇异值的相对比例向量$\hat{\mathbf{p}}$,表示为:

$$\hat{\mathbf{p}} = \frac{\tilde{\mathbf{s}}}{\|\tilde{\mathbf{s}}\|_2}$$

[0056] 其中,$\|\tilde{\mathbf{s}}\|_2 = \sqrt{\sum_i \tilde{s}_i^2}$,$\tilde{s}_i$表示预测的初始奇异值向量$\tilde{\mathbf{s}}$中的第$i$个分量。

[0057] 在非梯度计算模式下,利用输入矩阵H的F范数作为尺度因子C,记为$C = \|\mathbf{H}\|_F$,对相对比例向量$\hat{\mathbf{p}}$进行缩放。预测的初始奇异值矩阵$\hat{\mathbf{s}}$由两者相乘得到:

$$\hat{\mathbf{s}} = C \cdot \hat{\mathbf{p}} = \|\mathbf{H}\|_F \cdot \frac{\tilde{\mathbf{s}}}{\|\tilde{\mathbf{s}}\|_2}$$

[0058] 最后,对初始奇异值矩阵$\hat{\mathbf{s}}$进行降序排序操作以符合SVD的标准定义。

[0059] 本申请的奇异值解码器将一个困难的、不稳定的绝对值回归问题,成功通过神经网络解耦为一个具有稳定的比例预测问题,模型仅需学习不同奇异值之间的相对关系和衰减趋势,这与矩阵 H 的绝对能量尺度无关,极大地稳定了训练过程中梯度不稳定问题。同时采用数学公式进行简单的尺度放缩计算,通过利用计算输入矩阵H的F范数这一简单数学操作来校准最终的绝对尺度。通过这种自适应缩放机制,本申请的Transformer模型能够准确地预测奇异值的相对分布,并利用$\|\mathbf{H}\|_F$这一稳定的标量锚点将其缩放到正确的绝对量级,从而极大地提升了奇异值预测的稳定性和准确性。

[0060] 在本申请一种具体的实施方式中,所述后处理模块包括两个并行的正交引导模块以及映射模块;

所述两个并行的正交引导模块分别对所述发射端初始预编码矩阵和接收端初始处理矩阵,在前向传播过程中施加两次迭代,从而重塑出发射端预编码矩阵和接收端处理矩阵;其中,所述正交引导模块还用于在SVD近似网络训练过程中,提供指向正交流形的密集梯度,从而辅助优化训练。

[0061] 所述映射模块用于对所述初始奇异值矩阵进行映射得到奇异值矩阵。

[0062] 为解决神经网络输出的U, V矩阵难以满足$U^H U = I$正交性约束的问题,本申请引入了一种可微的正交引导模块,I表示单位矩阵。

[0063] 传统AI方法通常是在损失函数中加入一个正交惩罚项(如$\|U^H U - I\|_F$),但这是一种软约束,效果有限且训练不稳定。本申请的灵感来源于求解酉矩阵的经典数值方法:牛

顿-舒尔茨迭代(Newton-Schulz iteration)。该算法具有二阶收敛性,能将一个接近正交的矩阵快速拉回到正交流形上。其核心迭代公式为:

$$U_{k+1} = 0.5 \times U_k \times (3I - U_k^H U_k)$$

[0064] 传统方法需要迭代多次直至收敛(即$U^H U \to I$),这在神经网络中是不可行的,因为它计算开销大且难以反向传播。本申请对其进行了关键性改造,使其适配神经网络。本申请不寻求一次性收敛,而是将迭代次数k固定为一个极小值,例如k=2。本申请将此固定迭代次数的计算过程,实现为一个自定义的、完全可微的神经网络层,称之为二阶截断正交引导模块。该模块被嵌在解码器之后、损失计算之前。它在神经网络中的作用不是一个SVD求解器,而是一个梯度引导器。在前向传播时,它将解码器输出的原始U、V矩阵施加两次迭代,使其输出一个强烈倾向于正交的结果。在反向传播时,该模块为网络提供了一个结构化的、指向正交流形的密集梯度,高效地辅助复合损失函数进行优化。这种可微的硬约束引导方式,远优于传统的软约束惩罚。

[0065] 在本申请一种具体的实施方式中,在SVD近似网络的训练过程中采用复合损失函数作为每次迭代训练的损失函数,所述复合损失函数包括重建精度损失和结构准确性损失,并采用随着迭代次数动态增长的权重变量调整所述重建精度损失和结构准确性损失。

[0066] 本申请的神经网络需要同时优化两个目标:重建精度损失(L_{Recon},即$\| H - U\Sigma V^H \|$)和结构准确性损失(L_{Ortho},即$\| U^H U - I \|$)。

[0067] 本申请发现,这两个目标在训练初期可能是冲突的。如果过早地强制正交(即L_{Ortho}权重过高),网络会难以学习重建任务;反之,如果只关心重建,最终的U, V矩阵将不满足正交性。为平衡这两个任务,本申请设计了复合损失函数:

$$L_{total} = L_{Recon} + w(t) \times L_{Ortho}$$

[0068] 关键在于,权重$w(t)$不是一个固定的超参数,而是一个随训练轮次t动态增长的变量。本申请采用一种课程学习的策略:

训练初期,t较小,设置一个较小的初始权重$w(t) = w_{start}$(例如0.06),w_{start}表示初始权重。此时$L_{total} \approx L_{Recon}$。模型将专注于重建任务,即快速学习SVD的主体特征,保证收敛速度。训练末期,t较大,权重$w(t)$随t线性增长至一个较大的值$w(t) = w_{end}$(例如2.0),w_{end}表示结束权重。此时模型在重建任务基本完成后(L_{Recon}已显著下降),开始加强对正交性的结构化约束,精调U和V矩阵的细节。本申请通过动态权重策略,协同正交引导模块,确保了模型在训练全程的稳定性和最终的高精度。该策略引导模型先学习重建,后精调结构,符合认知规律。

[0069] 本申请提供了一种基于双路Transformer和动态课程学习的鲁棒SVD近似方法,包括获取MIMO系统的信道矩阵,并输入至训练完成的SVD近似网络中,使其将所述信道矩阵分解为列视角序列和行视角序列,并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理,从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵。本申请通过双路并行编码器架构和内部的线性注意力机制,并结合高效的MLP解码器,可以大幅度提高分解效率和准确性,满足了无线通信低时延、实时处理、高准确性的要求。此外,本申请的自适应F范数奇异值缩放策略,将不稳定的绝对值回归问题转化为稳定的相对比例预测,有

效克服了奇异值量级差异悬殊带来的训练不稳定问题,使得模型对不同信道质量均具有良好的预测稳定性。

[0070] 在本申请一种具体的实施方式中,在S200之后,所述方法还包括:

利用所述发射端预编码矩阵、接收端处理矩阵和奇异值矩阵完成信号传输。

[0071] 本申请提出的SVD近似方法,可广泛应用于无线通信系统的物理层信号处理,示例性的,基站端利用训练好的SVDNet对下行信道矩阵$\mathbf{H}$进行快速推理,得到正交的右奇异矩阵$\mathbf{V}$作为预编码矩阵,实现空间多路复用,显著降低传统迭代算法带来的计算时延。利用SVDNet输出的高精度奇异值向量$\mathbf{s}$,结合注水算法(Water-filling Algorithm)动态调整各数据流的发射功率,从而最大化信道容量。在用户终端(UE)部署轻量化的SVDNet模型,对下行信道进行特征分解,仅提取并反馈$\mathbf{V}$矩阵的主特征向量,从而大幅降低上行链路的反馈开销。

[0072] 为了验证本申请的技术效果,本申请在PyTorch框架下实现,使用NVIDIA A40图形处理器(Graphics Processing Unit, GPU)进行训练和测试。优化器采用AdamW,初始学习率设置为$2e^{-4}$,批次大小(Batch Size)设置为1024。动态权重 从0.06线性增长至2.0。

[0073] 示例1 训练收敛性分析

为验证本申请技术方案的有效性和稳定性,记录了模型在验证集上的损失下降过程,如图4和图5所示。如图4和图5所示,本申请的训练过程表现出如下特征:

在训练初期(Epoch 1-200),重建损失和正交损失均迅速下降。这归功于的双路架构提供了高效的特征提取,以及的动态权重策略在初期专注于重建任务。在训练中后期(Epoch 200-800),学习率保持稳定,重建损失和正交损失缓慢下降,网络进入精调阶段。

[0074] 如图6所示,总的损失在大约300个epoch时降低至0.6以下。在训练末期(轮次在800及以上),学习率依策略下降(采用了ReduceLROnPlateau学习率调度机制),如图7所示。同时动态权重$w(t)$达到最大值2.0,网络开始全力优化正交性。最终,总AE收敛至0.571的低水平,同时正交损失收敛至0.01以下(约0.008)。

[0075] 上述结果表明,本申请的技术方案可以协同工作,使网络稳定收敛并同时满足高重建精度和强正交性约束。

[0076] 示例2 计算复杂度对比

为验证本申请的低复杂度优势,在NVIDIA A40 GPU上,使用Batch Size=1,对比本申请模型(SVDNet)与PyTorch内置的传统SVD算法(torch.linalg.svd)处理5000个信道样本所需的总时间,参见表2:

表2 本申请与传统SVD算法计算效率对比

本申请模型用时	0.016965秒
传统方法用时	0.031644秒
用时为传统方法的0.536倍	

[0077] 如表1所示,本申请的AI算子用时仅为传统SVD方法的53.6%,计算速度提升近2倍。这证明了本申请的轻量化设计是高效且成功的。

[0078] 值得说明的是,本申请中的术语“第一”、“第二”仅用于描述目的,而不能理解为指示或暗示相对重要性或者隐含指明所指示的技术特征的数量。由此,限定有“第一”、“第二”的特征可以明示或者隐含地包括一个或者更多个该特征。在本申请的描述中,“多个”的含义是两个或两个以上,除非另有明确具体的限定。

[0079] 以上内容是结合具体的优选实施方式对本申请所作的进一步详细说明,不能认定本申请的具体实施只局限于这些说明。对于本申请所属技术领域的普通技术人员来说,在不脱离本申请构思的前提下,还可以做出若干简单推演或替换,都应当视为属于本申请的保护范围。

S100
获取MIMO系统的信道矩阵
S200
将信道矩阵输入至训练完成的SVD近似网络中，使其将信道矩阵分解为列视角序列和行视角序列，并对列视角序列和行视角序列分别并行进行线性编码、解码以及引导处理，从而分解出发射端预编码矩阵、接收端处理矩阵和奇异值矩阵

图1

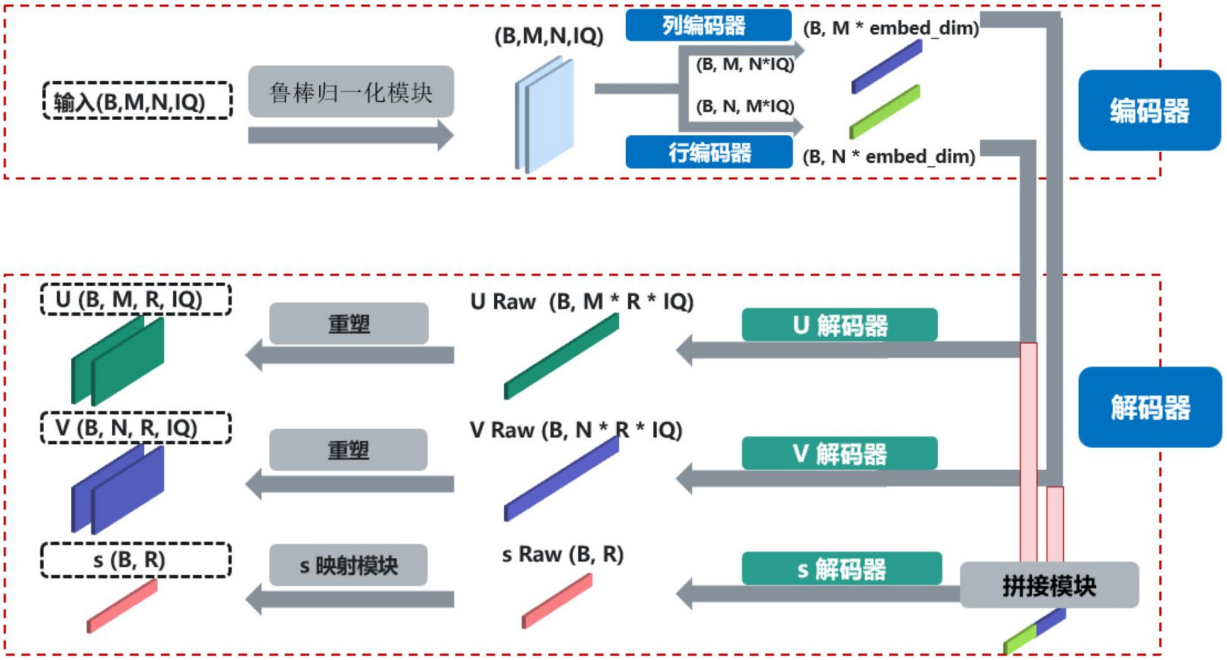
输入(B,M,N,IQ)
鲁棒归一化模块
(B,M,N,IQ)
列编码器
(B, M, N*IQ)
(B, N, M*IQ)
行编码器
(B, M * embed_dim)
(B, N * embed_dim)
编码器
U (B, M, R, IQ)
重塑
U Raw (B, M * R * IQ)
U 解码器
V (B, N, R, IQ)
重塑
V Raw (B, N * R * IQ)
V 解码器
s (B, R)
s 映射模块
s Raw (B, R)
s 解码器
拼接模块
解码器

图2

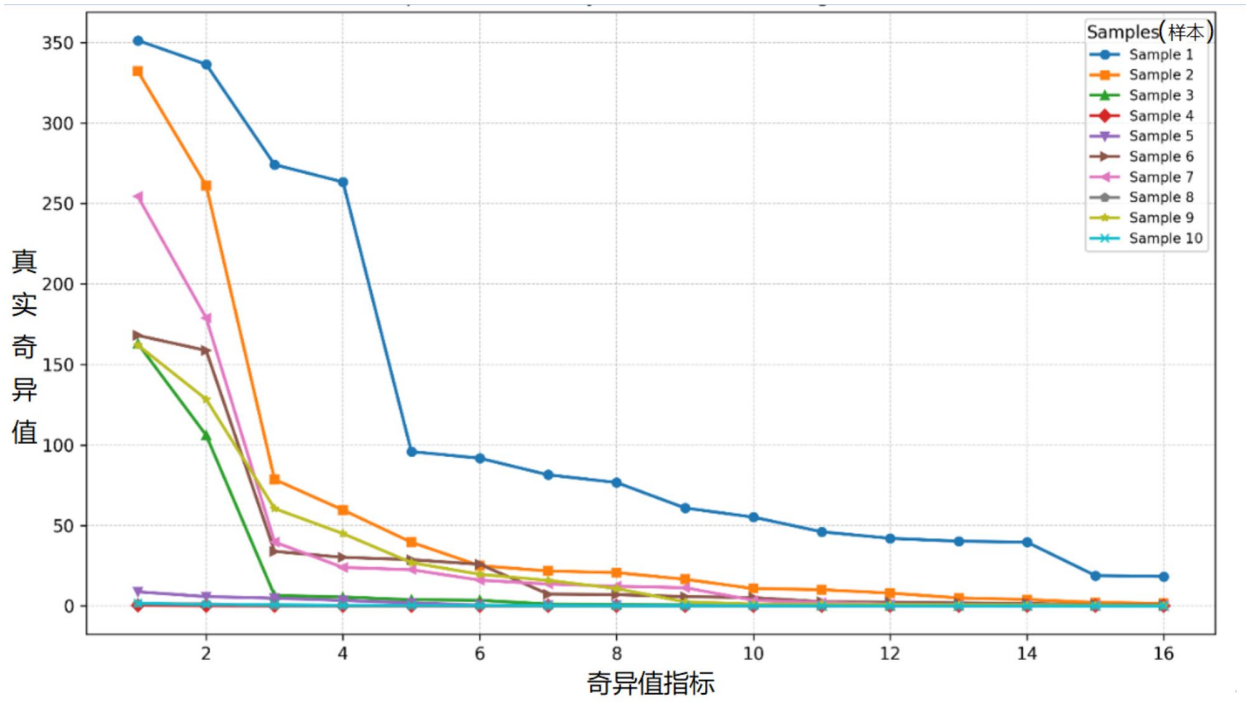
Samples(样本)
Sample 1
Sample 2
Sample 3
Sample 4
Sample 5
Sample 6
Sample 7
Sample 8
Sample 9
Sample 10
真实奇异值
奇异值指标
0
50
100
150
200
250
300
350
2
4
6
8
10
12
14
16

图3

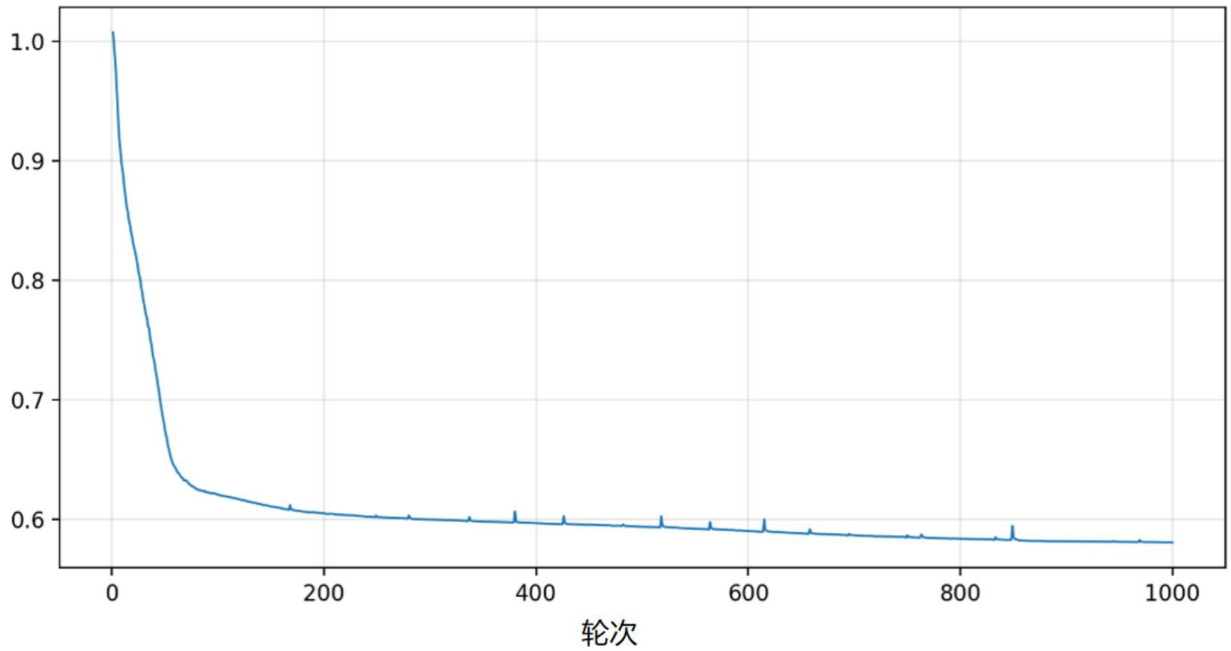
1.0
0.9
0.8
0.7
0.6
0
200
400
600
800
1000
轮次

图4

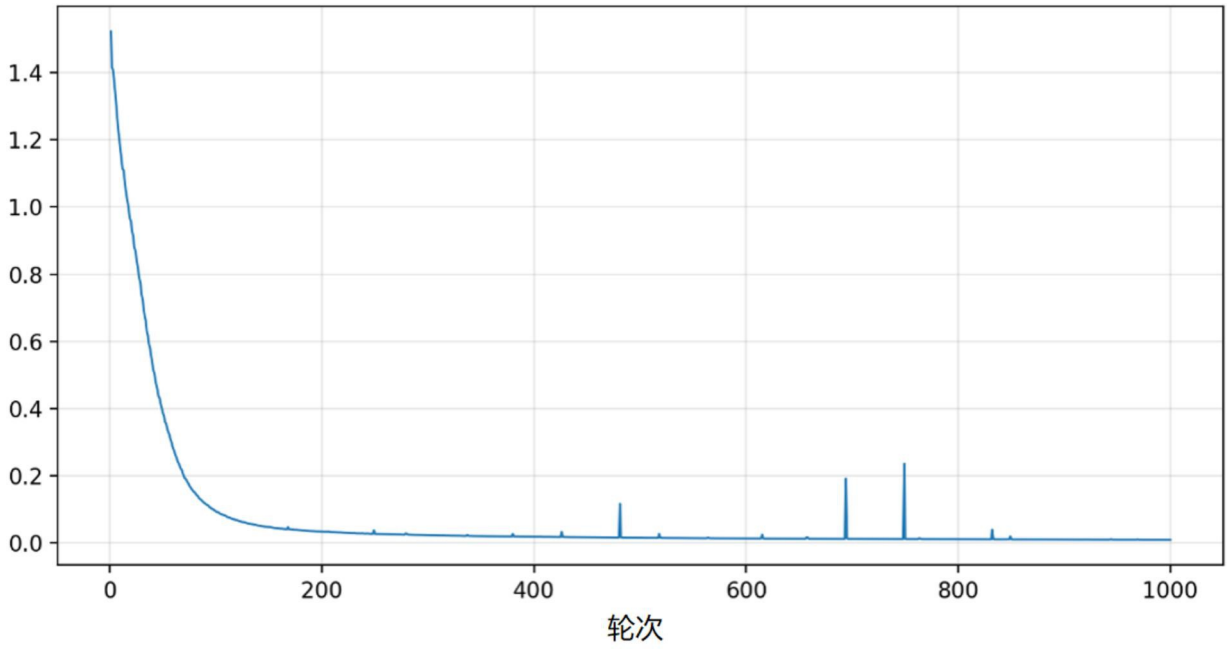
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
0
200
400
600
800
1000
轮次

图5

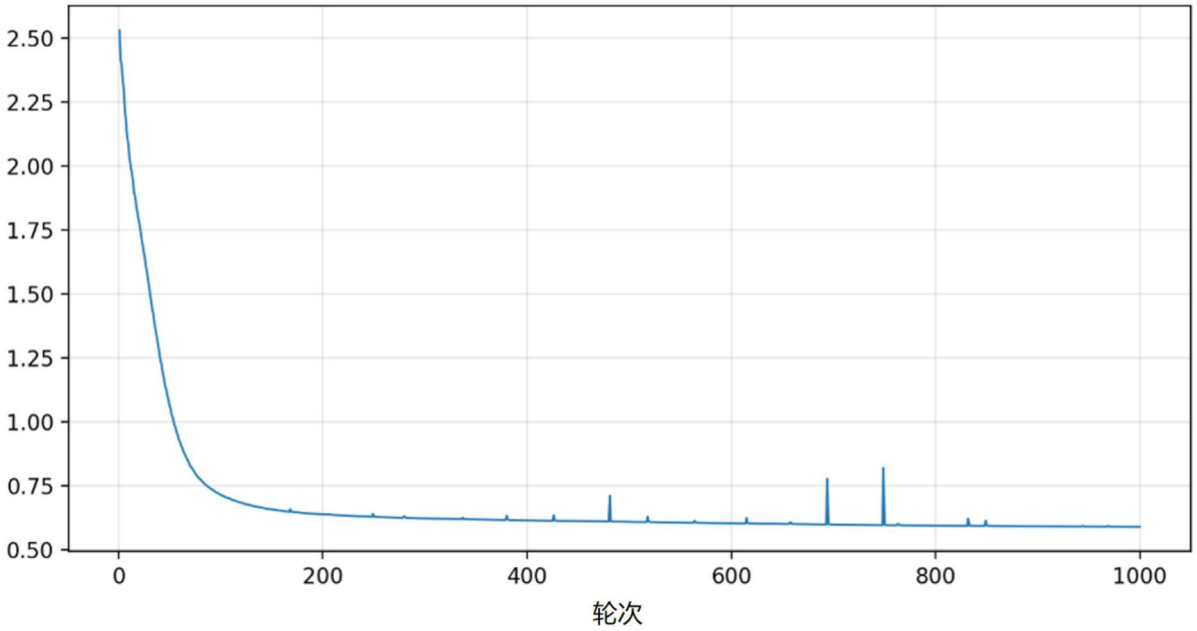
2.50
2.25
2.00
1.75
1.50
1.25
1.00
0.75
0.50
0
200
400
600
800
1000
轮次

图6

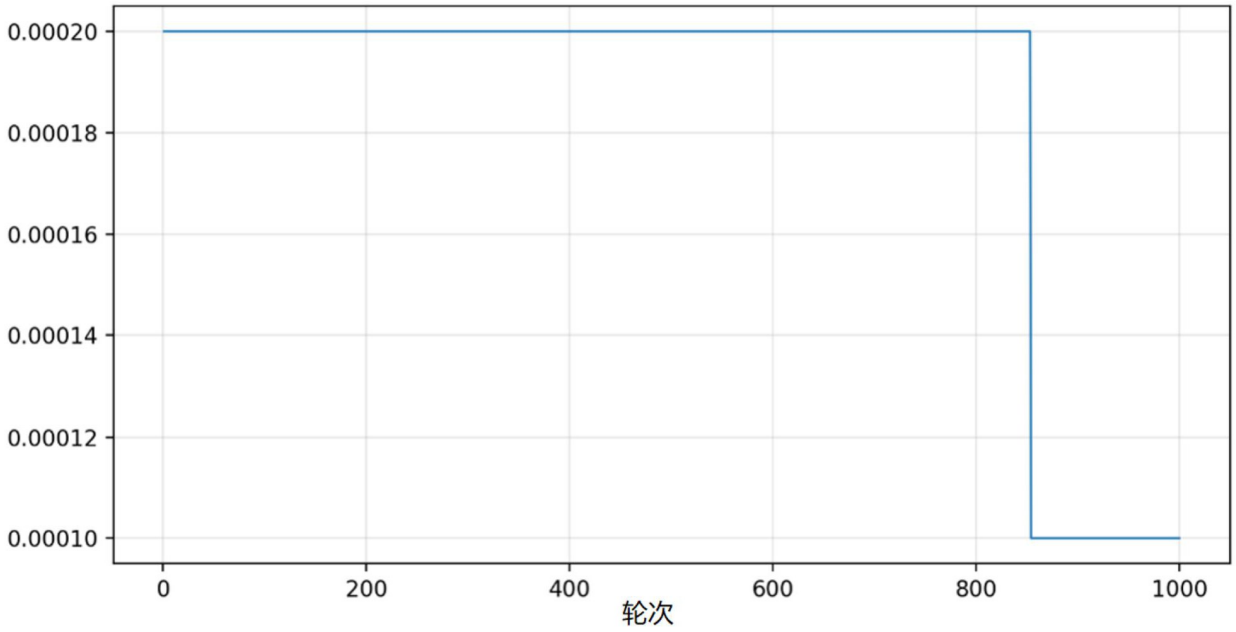
0.00020
0.00018
0.00016
0.00014
0.00012
0.00010
0
200
400
600
800
1000
轮次

图7